NLPDL期末Project

王柯然 2100017727

2024 年 1 月 11 日

1. 实验背景

   很多时候，我们在微调了一个模型之后，又有了新的需求。为了解决这个需求，我们是直接微调之前的模型，还是重新微调一个模型呢？

   在这个实验中，我们选取两个任务，分别是摘要和翻译，对一个模型进行测试，通过对比两个模型的翻译能力，以及摘要模型在重新微调前后的摘要能力变化，得到结论。

2. 实验方法

   通过对比两种训练方式，我们打算按照以下方式进行实验：

   (a) 在模型0上用摘要数据集训练得到模型1，并随后在模型1上用翻译数据集训练得到模型2。

   (b) 在模型0上用翻译数据集训练得到模型3。

   (c) 对比模型2和模型3的指标表现以及训练时间对比。

3. 实验设计

   (a) 模型0选取

   由于大部分的预训练模型都是基于英语文本的，而我们要做的是中文的摘要和翻译，所以我们选取了mT5这一模型，这个模型既可以做摘要，又可以做翻译。

   mT5分为large，base和small，为了更好的表现效果，我选取的是mT5-large

   对应的模型地址是：https://huggingface.co/google/mt5-large

   它包括了101种语言，参数量大概为1B

   mT5: A massively multilingual pre-trained text-to-text transformer

   可以通过添加prefix来指定任务类型，例如summarization，translation……

   (b) 数据集准备——摘要数据集

   我们要训练的是一个中文模型，所以我选取了一个常见的中文数据集NLPCC，涵盖了2017年的各种新闻及其标题，总共有5万条数据。

   这个数据集中的标题，我们可以作为训练的摘要，而新闻本体则是模型的输入，对此进行训练。

   另外由于文本比较长，我们还需要对他进行一些预处理。把所有长度大于1000的句子进行截断，只保留前面的部分

   如图为摘要数据集的前几条数据：

```
{"version": "0.0.1",
 "data":
[
    {
        "title": "知情人透露章子怡怀孕后,父母很高兴。章母已开始悉心照料。据悉,预产期大概是12月底",
        "content": "四海网讯,近日,有媒体报道称:章子怡真怀孕了!报道还援引知情人士消息称,“章子怡怀孕大概四五个月,预产期是年底前后,项
    },
    {
        "title": "青海首次野外发现濒危大火烈鸟 尚不清楚具体来源",
        "content": "中新社西宁11月22日电(赵凛松)青海省林业厅野生动植物和自然保护区管理局高级工程师张毓22日向中新社记者确认:“经过中
    },
    {
        "title": "东莞少女妈妈不愿带孩子 自杀被救后携女出走",
        "content": "内容提要:因为早早结婚,今年20岁的杨丽(化名)已经是一个三岁小孩的妈妈。今年10月31日,和老公大吵一架的她离家出走,直
    },
```


图 1: Summarization

(c) 数据集准备——翻译数据集

另外我们还需要选取一个翻译数据集用于训练模型1，以及直接微调模型0。

为了保证模型前后的统一性，我们采用的翻译数据集是基于摘要数据集产生的。

通过调用google翻译的api，我们对摘要数据集的content进行了翻译，从而产生了翻译数据集。

对它我们也进行相同的预处理，即输入进行截断以保证模型的训练速度和效果。

如图为翻译数据集的前几条数据：


```
{
    "zh": "四海网讯,近日,有媒体报道称:章子怡真怀孕了!报道还援引知情人士消息称,“章子怡怀孕大概四五个月
    "en": "Four Sea Network News, recently, there are media reports: Zhang Ziyi is pregnant!
}
{
    "zh": "中新社西宁11月22日电(赵凛松)青海省林业厅野生动植物和自然保护区管理局高级工程师张毓22日向中
    "en": "China News Agency, Xining, November 22 (Zhao Yisong) Zhang Yu, a senior engineer
}
{
    "zh": "内容提要:因为早早结婚,今年20岁的杨丽(化名)已经是一个三岁小孩的妈妈。今年10月31日,和老公大
    "en": "Summary of content: Because of getting married early, Yang Li (pseudonym), 20, is
}
```


图 2: Translation

(d) 评估指标

i. BLEU

对于摘要语言任务，常用的一个指标是ROUGE，它通过计算输出结果与参考的召回率和精确率，来得到摘要结果的ROUGE指数

即：

$$Recall = \frac{\text{Number of overlapping words}}{\text{Total number of words in reference summary}}$$

$$Precision = \frac{\text{Number of overlapping words}}{\text{Total number of words in generated summary}}$$

$$ROUGE = F1(Recall, Precision) = \frac{1}{\frac{1}{Recall} + \frac{1}{Precision}}$$

这一指标通过召回率Recall来计算了生成的摘要包含了多少参考摘要，而通过精确率计算了摘要有多少是相关的。

ii. ROUGE

对于翻译语言任务，我们通常用BLEU或者sacreBLEU。

BLEU它不衡量模型生成输出的可懂度或语法正确性，而是使用统计规则来确保生成输出中的所有单词也出现在目标中。此外，如果相同单词在目标中没有重复，则有规则惩罚相同单词的重复并输出比目标中短的句子

而sacreBLEU则不需要BLEU的前置分词条件。

(e) 训练方法与参数

我们采用的是PEFT+lora的微调方式，因为模型本身比较大，直接从头开始训起的花费很大。所以采用这种微调的方式。

训练参数： $epochs = 5, batch = 4 \times 4, learning_rate = 5.6 \times 10^{-5}, weight_decay = 1 \times 10^{-2}$

4. 实验数据

(a) 摘要模型1

Seeds	$seed = 111$	$seed = 222$	$seed = 333$	ave	var
Rouge1	19.42	19.35	19.89	19.55	0.057
Rouge2	4.20	4.19	4.28	4.22	0.0016
RougeL	19.36	19.17	19.79	19.44	0.067
RougeL	19.36	19.17	19.79	19.44	0.067

表 1: Data of Model1

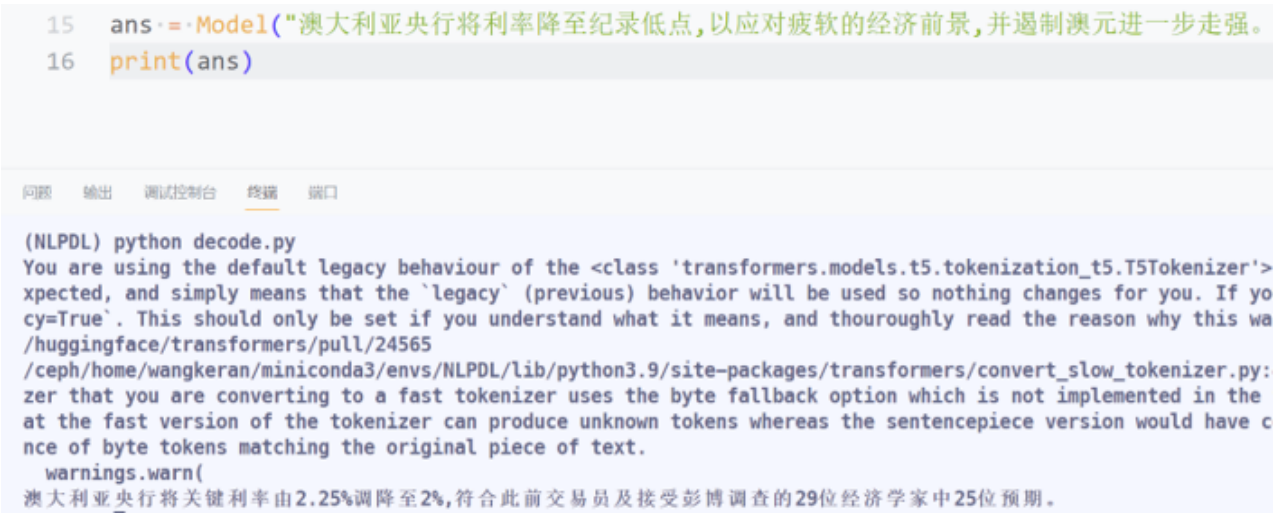

图 3: Instance of Model1

(b) 翻译模型2

(c) 翻译模型3

5. 实验结论

Seeds	$seed = 111$	$seed = 222$	$seed = 333$	ave
SacreBLEU	9.18	10.33	9.26	9.59

表 2: Data of Model2

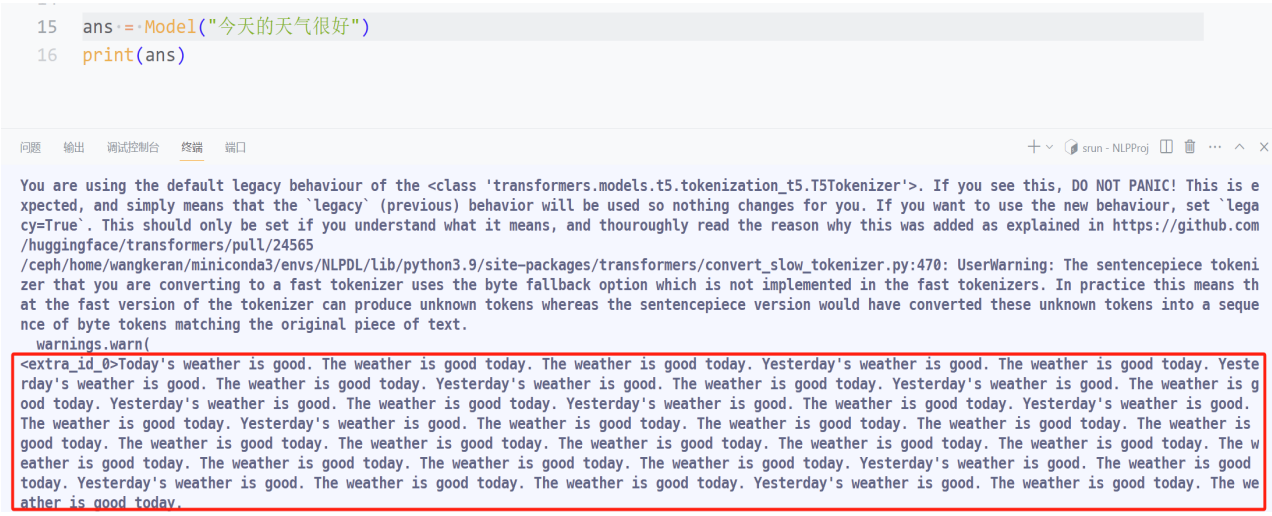

图 4: Instance of Model2

(a) 训练二次的模型并没有直接训练一次的模型表现好，可能是因为两次任务内容并不相关，不能达到两个数据集产生更好性能的效果。

(b) 在训练之后，之前的能力会有丢失，并不能保持原来的摘要水平。

(c) 对于训练的开销而言，二次训练对数据集和训练资源都有更高的需求，是不如直接微调一个新的模型的。

6. 实验的局限与缺陷

(a) 只在一个模型大小上进行了实验，实验的结论不一定具有泛用性，如果有时间可以选取small、base等参数量重新进行。

(b) 训出来的结果与SOTA有较大的差异，还需要进一步调整超参数以获得更好的结果。

(c) 这一数据集的文本质量并不高，出现了很多非正式文本的内容，可以选取更好的数据集进行训练。

(d) 这两个任务种类并不是很相关，可以选取两个比较相关的任务重新评估，例如摘要和问答。

7. 参考文献

(a) 微调代码参考

https://huggingface.co/learn/nlp-course/zh-CN/chapter7/4?fw=tf

https://huggingface.co/learn/nlp-course/zh-CN/chapter7/5?fw=tf

(b) 数据集及参考处理

https://zhuanlan.zhihu.com/p/341398288

https://pypi.org/project/pygoogletranslation

Seeds	$seed = 111$	$seed = 222$	$seed = 333$	ave
SacreBLEU	13.32	13.31	13.56	13.40

表 3: Data of Model3

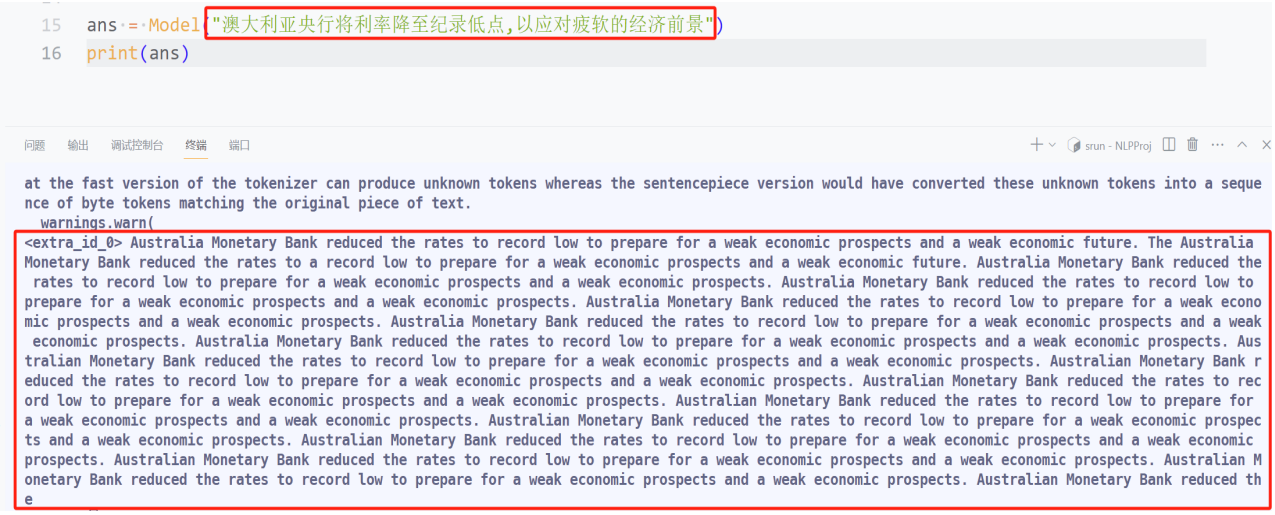

图 5: Instance of Model3

(c) 代码仓库

https://github.com/WKR233/NLPDL/FinalProject